



UNIVERSITÉ ÉVRY
PARIS-SACLAY

RAPPORT DE STAGE

Comparaison d'annotation structurale
des gènes dans la base  **GBOT** 
Genome Browser & Orthologs Tracker.

Auteur :

Akshay MOHAMMED KHOKAN

Encadré par :

Franck SAMSON & Véronique BRUNAUD

Table des matières

RÉSUMÉ	2
INTRODUCTION	2
MATÉRIEL & MÉTHODES.....	3
1. Matériel.....	3
2. Méthodes	6
<i>2.1 Détection des annotations non inclus par Helixer ou par les experts.....</i>	<i>7</i>
<i>2.2 Comparaison des features Helixer et Expert en commun.....</i>	<i>8</i>
<i>2.3 Comparaison des régions UTR des ARNm Helixer et Expert.....</i>	<i>11</i>
<i>2.4 Exportation des résultats.....</i>	<i>11</i>
RÉSULTATS & DISCUSSIONS.....	12
CONCLUSION & PERSPECTIVES	17
REMERCIEMENTS	18
RÉFÉRENCES	19

Comparaison d'annotation structurale des gènes dans la base GBOT (Genome Browser & Orthologs Tracker).

Akshay MOHAMMED KHOKAN¹, Franck SAMSON², Véronique BRUNAUD²

¹Etudiant en Licence Double-Diplôme : Biologie et Informatique

²Ingénieur(e) de Recherche INRAE : Tuteur et Co-encadrante du stage

RÉSUMÉ

Ce stage a porté sur le développement d'un outil bio-informatique devant comparer deux annotations génomiques : une annotation de référence et une annotation prédite par Helixer (*Felix Holst et al.*, 02/2023), un outil basé sur le Deep Learning. Nous avons développé en Python un outil, permettant d'analyser et de comparer la structure des gènes à partir de la base de données GBOT. Des requêtes SQL ont été utilisées pour l'interroger, facilitant l'extraction et l'analyse des données biologiques pertinentes. L'outil génère des rapports détaillés mettant en évidence les différences entre les annotations, et sera intégré à l'interface web GBOT pour permettre une visualisation interactive des résultats. Ce travail contribue à l'amélioration de la qualité des annotations génomiques et offre une solution réutilisable pour des comparaisons futures. GBOT est accessible via l'URL suivant : <http://stat.genopole.cnrs.fr/server/GBOT/index.html>.

INTRODUCTION

L'annotation génomique est une étape cruciale en Biologie, car elle sert à identifier les éléments importants d'un génome, tels que les gènes, exons, introns ou encore les régions régulatrices. Face à la diversité des espèces et à la complexité croissante des génomes, de nouvelles approches, notamment basées sur l'intelligence artificielle, ont vu le jour pour améliorer la précision des annotations. Dans ce contexte, Helixer, un outil d'annotation de nouvelle génération utilisant des réseaux de neurones profonds, offre une alternative prometteuse aux méthodes classiques. En effet, les annotations structurales faites par les experts se basent sur RNA-Seq (contrairement à Helixer). Cependant, il est essentiel de comparer les annotations générées par Helixer avec les annotations de référence pour évaluer leur fiabilité, et détecter les divergences structurales.

Ces annotations structurales peuvent être visualisées sur des Genome Browsers, et le stage porte ici sur un d'eux : GBOT (Genome Browser & Orthologs Tracker). Bien que des espèces de drosophiles y soient présents, seuls les génomes d'espèces de plantes (telles que *Arabidopsis Thaliana*, *Brachypodium distachyon*, *Malus domestica*, *Rosa chinensis*) ont été annotés par Helixer.

Ce stage s'inscrit ainsi dans cette démarche de comparaison d'annotations génomiques, avec pour objectif le développement d'un outil automatisé en Python permettant :

- D'analyser les différences entre deux jeux d'annotations (référence vs Helixer),
- D'interroger efficacement une base de données relationnelle (GBOT) via SQL,
- Et de générer des rapports visuels intégrables au site web de GBOT pour faciliter l'interprétation des résultats.

Ce travail permet d'évaluer l'efficacité de l'intelligence artificielle dans l'annotation génomique, bien qu'il soit limité uniquement aux génomes de plantes.

MATÉRIEL & MÉTHODES

1. Matériel

Le travail portant sur GBOT, cet outil a été conçu pour explorer les relations d'homologie entre les gènes et les protéines. Il propose une nouvelle plateforme de visualisation qui facilite l'étude des familles de gènes homologues et la prédiction des orthologues. (*F.Samson & S.Aubourg, 09/2024*)




Figure 1 : Interface web de GBOT. Search pattern : Permet de chercher une séquence spécifique dans le génome. Blast sequence : Lance une recherche BLAST à partir d'une séquence donnée. PFAM motif : Affiche les domaines protéiques détectés dans les gènes. mRNA : Visualise les ARNm annotés dans la région sélectionnée. Blast result : Montre les résultats alignés de la recherche BLAST. Feature menu : Donne accès aux différentes annotations disponibles. CDS : Affiche les séquences codantes (exons traduits) des gènes. Select species : Choisis les espèces à afficher pour la comparaison. Sequence position : Indique la position exacte des séquences génomiques. Chromosome view : Représente les alignements des chromosomes entre espèces. Blast result (comparatif) : Montre les alignements BLAST entre les gènes homologues de différentes espèces.

Il aide à mieux comprendre l'évolution des gènes à travers différentes espèces et à transférer les connaissances fonctionnelles entre elles, en particulier dans les contextes d'annotation de génomes. Il est alors important de spécifier son fonctionnement, traduit par la figure suivante :




Figure 2 : Schéma fonctionnel de GBOT. L'interface web utilise uniquement du JavaScript pour la couche de présentation, connectée à une base de données PostgreSQL qui permet de stocker et d'interroger les données génomiques. Une couche codée en Python sert d'intermédiaire entre le navigateur du client et le serveur de base de données via une API. L'interface WEB, permettant de visualiser les relations d'homologie au sein des familles de gènes entre plusieurs espèces, s'appuie sur WASM et affiche les requêtes de la base de données via des sorties json.

Afin d'étudier les différences d'annotations génomiques, un outil bio-informatique de comparaison a été codé en Python 3.12 pour la logique, avec des appels à la base de données PostgreSQL pour l'extraction d'informations de la base de données directement codé en SQL. Cependant, le travail n'a porté que sur les plantes car l'équipe s'est concentrée sur l'étude des plantes avec l'IPS2 et n'a donc pas recherché l'annotation Helixer sur les drosophiles contenues dans la base.

Les annotations génomiques dans nos jeux de données ont été obtenues de manière différente. En effet, Helixer est un outil de novo de prédiction de modèles de gènes eucaryotes, qui combine Deep Learning et modèles de Markov cachés (HMM). L'objectif est de produire des annotations cohérentes biologiquement, directement à partir de séquences

d'ADN brutes, sans besoin de données expérimentales supplémentaires. Grâce à des réseaux neuronaux entraînés, Helixer identifie avec précision des éléments clés comme les codons start/stop, les sites d'épissage ou encore les UTR. Ces prédictions sont ensuite raffinées par un HMM, qui vérifie si elles concordent avec les lois biologiques (phases codantes, types d'introns, etc.). Le résultat final est fourni sous format .gff3, entièrement lisible par les Genome Browsers, ce qui permet une visualisation directe des modèles de gènes annotés. L'annotation experte a été obtenue via RnaSeq, contrairement à Helixer qui apprend à partir des annotations RefSeq et Phytozome13 (pour celles de génomes de plantes) et qui une fois entraîné, n'a plus besoin de celles-ci, ni d'RNAseq pour faire ses prédictions. En effet, l'annotation experte des gènes à partir de données RNAseq repose sur l'utilisation de séquences d'ARN messagers extraites, séquencées, puis alignées sur le génome pour reconstituer la structure des gènes exprimés. Cette approche permet de repérer précisément les exons, les sites d'épissage, les variants d'épissage (isoformes) ainsi que les positions exactes de début et fin de transcription. Les ARN sont ensuite alignés et des modèles de gènes sont établis via ces alignements. On notera une différence majeure entre les deux annotations : Helixer ne prend en compte qu'un seul transcrit, tandis que l'annotation par RNAseq prend en compte tous les transcrits alternatifs.

Bien que GBOT offre la possibilité de visualiser des features tels que les ARNnc, les PFAM et les ARNt, le travail de comparaison a porté uniquement sur les séquences codantes (CDS) et les ARNm, car seuls ces features ont été prédits par Helixer pour les génomes de plantes de la base de données.

Concernant l'annotation des CDS dans la base GBOT, elle a été réalisée par les consortiums responsables de l'annotation de chaque espèce végétale. Par exemple, pour *Arabidopsis thaliana*, les données de séquences proviennent de la version TAIR10, tandis que les annotations des CDS et ARNm ont été récupérées depuis Araport11, la dernière version d'annotation structurale de référence. En ce qui concerne *Malus domestica*, l'annotation du génome utilisée dans GBOT est tirée de l'assemblage de haute qualité GDDH13 v1.1, développé par l'équipe du Bucher Lab (INRAE, Angers) mais contrairement à *Arabidopsis thaliana*, aucune annotation de transcrits alternatifs n'y est fournie.

2. Méthodes

Le travail de comparaison d'annotations génomiques ayant été divisé en plusieurs couches d'analyse, montrées par le diagramme de flux suivant :




Figure 3 : Diagramme de flux de l'outil de comparaison d'annotations structurales. L'outil s'appuie sur les modules GBOT d'où leur importation avant de créer les méthodes. Les sections suivantes détaillent chacune d'entre elles.

2.1 Détection des annotations non inclus par Helixer ou par les experts

Cette première couche permet de repérer ce qu'Helixer a prédit mais que les experts n'ont pas annoté. Elle permet aussi la détection des features annotés par les experts dont la prédiction n'a pas été faite par Helixer. C'est via la méthode *find_MissingAnnotationsV1()* qu'on a pu établir cette première couche. Bien que cette méthode permette de travailler sur tous les types de features annotés par Helixer et les experts, son utilisation a porté uniquement sur les séquences codantes. En effet, dans la base de données GBOT, on peut retrouver tous les CDS d'une séquence chromosomique d'une espèce via une requête SQL. Cette requête permet alors d'obtenir tous les CDS annotés par les experts (donc les CDS alternatifs sont pris en compte), et les CDS annotés par Helixer. Une méthode *are_overlapping()* a été ainsi créée afin de voir si deux features se chevauchent.

La figure ci-contre montre comment les CDS chevauchants ont été repérés :




Figure 4A : Détection des chevauchements de CDS Helixer et CDS Expert. Il y a plusieurs cas de chevauchements, et la détection se fait en fonction des positions de départ et de stop des features. En effet, si $\min(\text{stop1}, \text{stop2}) - \max(\text{start1}, \text{start2}) > 0$, alors il y a chevauchement. Si la condition n'est pas respectée, Helixer a raté l'annotation experte ou inversement. C'est via ce raisonnement que nous avons pu repérer les rajouts et les manqués de l'annotation par Helixer.




Figure 4B : Détection des CDS ajoutés ou ratés par Helixer. (En rouge : Helixer, en bleu : l'annotation experte) Les CDS Helixer ne chevauchent aucunement une annotation de référence, et de même pour une annotation de référence qui ne chevauche aucunement un CDS Helixer. Le CDS est alors soit raté, soit ajouté par Helixer par rapport à l'annotation experte.

2.2 Comparaison des features Helixer et Expert en commun

Grâce à la méthode *are_overlapping()*, on a pu se focaliser sur les features Helixer et Expert qui se chevauchent. Cependant, un chevauchement ne signifie pas que les deux features sont identiques. C'est ainsi que la deuxième couche de travail a été établie par la méthode *compare_all_feats()*. Cette méthode fait appel aux méthodes *get_score()* et *obtain_both_feats()*, et *compare_both_feats()*. Avant de passer en revue la première méthode, il est important d'expliquer les autres.

La méthode *obtain_both_feats()* permet d'obtenir tous les features annotés simultanément par Helixer et par les experts (qui se chevauchent), et s'appuie donc sur la fonction *are_overlapping()*. Afin de comparer les features ensemble, un système de score d'identité a été mis en place. En effet, la méthode *get_score()* permet le calcul d'un score en prenant en compte une position de départ et une position de fin. La méthode *compare_both_feats()* quant à elle, permet de calculer le score d'identité entre deux features en les comparant exons par exons, puis prend en compte la disposition des introns pour fournir le type d'égalité dans lequel se trouvent les deux features.




Figure 5 : Différents types d'égalité de features (établi par le projet E2annot) "=" : Les exons ne sont pas tous pareils mais les chaînes d'introns le sont, "c" : Les introns de Helixer sont contenus dans l'annotation de référence, "k" : Les introns de Helixer contiennent l'annotation de référence, "m" Tous les introns de référence sont recouverts / matchés, "j" : Au moins un match entre les exons, "n" : Tous les introns de référence ne sont pas matchés.

Il existe effectivement plusieurs types de superpositions de features, et nous nous sommes appuyés sur le travail fourni par le projet *e2annot* (Extend Eukaryote Annotation with transcriptome data) pour que l'outil renvoie le type d'égalité de nos features.

Cependant, le type « = » n'a pas été considéré comme tel lors de la conception de l'outil de comparaison. En effet, nous

avons attribué le signe « = », si et seulement si les deux features étaient strictement identiques. Le type « ~ » a ainsi été créé pour classer les features quasiment identiques.

Comme dit précédemment, la méthode *compare_both_feats()* permet la comparaison exonique et intronique des features, afin de renvoyer le score d'identité et le type d'égalité dans lequel se trouvent les deux features. Pour calculer le score d'identité entre deux features, on a calculé via *get_score()*, ce même score pour chaque exon chevauchant celui (ou ceux) dans l'autre annotation. A l'issue du calcul de score pour chaque exon, la moyenne de chaque score calculé constitue le score d'identité. Pour chaque exon n'ayant pas de chevauchement avec un de l'autre annotation, on comptabilise le score local à 0. Ce système prend alors en compte alors les différents types de chevauchement qu'on peut avoir dans la figure suivante.




Figure 6 : Différents cas de types de CDS annotés (Annotation Helix : rouge / Annotation Experte : bleue)

5A : CDS Helix et CDS Expert ayant un ou plusieurs introns. **5B :** CDS Helix et CDS Expert ayant un seul exon. **5C :** CDS Helix ayant un ou plusieurs introns contre CDS expert n'ayant qu'un exon (l'inverse est possible). Des CDS identiques sont montrés en 4A et 4B, ils peuvent être différents bien que le type de structure soit pareil.

La méthode `compare_all_feats()` prend alors en compte un score seuil d'identité en paramètre et le type d'égalité des features qu'on souhaite voir. Elle applique ainsi `compare_both_feats()` à chaque chevauchement trouvé via `obtain_both_feats()`. On a donc un rapport généré avec le score et le type d'égalité des chevauchements pour tout un génome. Cependant, la méthode `compare_all_feats()` permet aussi de retrouver tous les transcrits alternatifs et prend le plus similaire à l'annotation Helix (l'isoforme ayant le plus grand score d'identité). Le rapport généré affiche tout de même une liste des transcrits alternatifs (s'il y en a) pour le transcrit désigné par `compare_all_feats()`.




Figure 7 : Helix VS Isoformes (Annotation Helix : rouge / Annotation Experte : bleue)

Bien qu'il y ait 2 isoformes, `compare_all_feats()` renverrait ici l'isoforme 1 (score à 100%) et le type d'égalité serait à « = ».

L'isoforme 2 aurait un score < 100 et a pour type d'égalité « m » mais serait placé dans la liste des transcrits alternatifs.

2.3 Comparaison des régions UTR des ARNm Helixer et Expert

Grâce aux méthodes évoquées dans les sections ci-dessus, nous avons pu étudier les régions UTR des ARNm Helixer et Expert. En effet, bien que les annotations de CDS soient quasiment ou exactement pareilles, les ARNm quant à eux peuvent avoir des différences d'annotations dans les régions UTR.




Figure 8 : Différences dans les annotations des ARNm au niveau des régions UTR (CDS Helixer : rouge, ARNm Helixer : orange / CDS Expert : bleu foncé, ARNm Expert : bleu clair)

Bien que les CDS ici soient identiques, ce n'est pas le même cas pour les ARNm qui sont presque similaires. Helixer présente un allongement en 3'UTR par rapport à la référence, et une délétion en 5'UTR par rapport à la référence.

Deux méthodes ont ainsi été créées afin de pouvoir comparer les régions UTR des deux annotations : `comparing_UTR()` et `compare_every_UTR()`.

La première méthode compare deux features en se focalisant sur les régions 5'UTR et 3'UTR. Elle identifie et renvoie uniquement la séquence présente dans une annotation mais absente dans l'autre, correspondant à une insertion. Afin d'analyser uniquement les régions UTR, nous avons obtenu les séquences des ARNm et des CDS via des requêtes SQL. Nous savons que les régions UTR correspondent aux parties non codantes de l'ARNm, donc l'ARNm privé du CDS. L'obtention des régions UTR s'est alors faite en excluant les séquences des CDS des ARNm. De plus, cette méthode fait aussi l'analyse des deux annotations d'ARNm via `compare_both_feats()`. Elle renvoie alors un rapport avec le format suivant : {Chromosome de référence, Gène de référence, Feature de référence, Feature Helixer, Liste des isoformes, Score d'identité, Type d'égalité, Différence en 5'UTR, Différence en 3'UTR}.

La deuxième méthode permet ainsi l'utilisation de la première pour l'entièreté d'une liste de features que nous avons obtenue via `compare_all_feats()`.

2.4 Exportation des résultats

Une dernière méthode a été créée pour analyser tous les génomes des plantes de la base de données : `exporting_results()`. En effet, elle permet de stocker tous les rapports générés dans des types de fichiers tels que .bed et .tsv, et ce pour chaque génome.

RÉSULTATS & DISCUSSIONS

Grâce à la méthode *exporting_results()*, nous avons obtenu des résultats pour l'ensemble des génomes de plantes de la base de données, à l'exception de la plante *Zea Mays*. Avant de nous intéresser aux fichiers .tsv et .bed créés via cette méthode, voici des figures résumant l'ensemble des résultats obtenus.




Figure 9 : Histogramme obtenu à la suite de l'utilisation de *findMissingAnnotations1()* sur tous les génomes. Helixer recouvre l'ensemble des CDS que les experts ont annotés. Les annotations ratées ou ajoutées par Helixer sont minimales, sauf pour la *Rosa chinensis* dont Helixer a annotés plus de CDS par rapport aux autres génomes. Pour le génome de *Zea mays*, aucune annotation par Helixer n'a pu être faite car la taille des chromosomes étant trop importante, il y a eu des problèmes de mémoire.

<u>Espèce</u>	<u>Helixer</u>	<u>Expert</u>
<u><i>Arabidopsis thaliana</i></u>	27035	48266
<u><i>Brachypodium distachyon</i></u>	30904	56835
<u><i>Malus domestica</i></u>	43640	45115
<u><i>Rosa chinensis</i></u>	43623	39668
<u><i>Solanum lycopersicum</i></u>	34074	29773

Figure 10 : Tableau récapitulatif des CDS annotés par Helixer et des CDS annotés par les Experts pour chaque génome. Le nombre de CDS Expert comprend aussi les CDS alternatifs, d'où un plus grand nombre qu'Helixer pour la plupart des génomes.

Bien que Helixer ait annoté moins de CDS que les experts pour la plupart des génomes, nous avons pu voir que la majorité des locis de référence était recouverte par l'annotation Helixer. Cela s'explique par le fait qu'un CDS annoté par l'outil basé sur Deep Learning peut chevaucher plusieurs transcrits alternatifs. Cependant, pour *Rosa chinensis*, Helixer a annoté plus de CDS que l'annotation experte avec 12196 CDS en plus, qui n'y sont pas compris. Le génome de *Solanum lycopersicum* présente aussi un cas où les CDS Helixer dépassent en nombre ceux annotés par les experts, avec 7677 ratés par l'outil. Les annotations Helixer pour les autres génomes paraissent cependant fiables, car les rajouts et les CDS manquants sont en petite quantité comparés aux CDS que les deux annotations ont su relever. Cela veut dire que les CDS Helixer recouvrent une majorité de transcrits alternatifs bien que moins nombreux que les CDS annotés par les experts.

Il faut tout de même remettre en question l'annotation du génome de *Malus domestica*, car les experts n'ont nullement annoté de transcrits alternatifs. En effet, le nombre de CDS annotés de part et d'autre est environ égal (43640 Helixer VS 45115 Expert), mais seulement 38005 CDS ont été prédits par les deux annotations (avec 7110 ratés et 5910 CDS ajoutés par Helixer).

Des fichiers .bed ont été générés : un premier pour révéler les CDS ajoutés par Helixer et un deuxième pour les CDS manqués par Helixer. Les fichiers ont été générés pour l'ensemble des génomes, mais ceux d'*Arabidopsis thaliana* et *Malus domestica* ont été étudiés de plus près.

A

ATH02	1025	2111	AT2G01008.1	0	1
ATH02	6571	6672	AT2G01021.1	0	1
ATH02	9648	9767	AT2G01023.1	0	-1
ATH02	50345	51487	AT2G01035.1	0	-1
ATH02	53326	54468	AT2G01045.1	0	-1
ATH02	68337	69884	AT2G01050.1	0	-1
ATH02	73456	74556	AT2G01060.2	0	-1
ATH02	73456	74902	AT2G01060.1	0	-1
ATH02	152481	152642	AT2G01310.1	0	-1
ATH02	171098	171343	AT2G01379.1	0	1
ATH02	249687	250181	AT2G01554.1	0	1
ATH02	332249	332770	AT2G01755.1	0	-1
ATH02	332249	332788	AT2G01755.2	0	-1

B

Chr05	87650	91257	MD05G1000300	0	-1
Chr05	177915	178151	MD05G1000600	0	-1
Chr05	1091054	1091527	MD05G1003000	0	-1
Chr05	1234489	1235314	MD05G1003600	0	-1
Chr05	1386427	1386689	MD05G1005200	0	-1
Chr05	1464306	1464497	MD05G1005700	0	1
Chr05	1486551	1487268	MD05G1006000	0	-1
Chr05	1523353	1523695	MD05G1006200	0	-1
Chr05	1624434	1625120	MD05G1006500	0	-1
Chr05	1634613	1634910	MD05G1006600	0	1
Chr05	1636289	1636896	MD05G1006700	0	-1
Chr05	1694371	1695440	MD05G1007100	0	-1
Chr05	1769931	1772953	MD05G1007400	0	1

C

ATH02	598112	599525	Arabidopsis_thaliana_Ch2_004052	0	-1
ATH02	613163	614739	Arabidopsis_thaliana_Ch2_004048	0	-1
ATH02	636287	636607	Arabidopsis_thaliana_Ch2_004043	0	-1
ATH02	792503	793028	Arabidopsis_thaliana_Ch2_004032	0	-1
ATH02	850349	850676	Arabidopsis_thaliana_Ch2_000090	0	1
ATH02	936085	936543	Arabidopsis_thaliana_Ch2_000099	0	1
ATH02	982173	982474	Arabidopsis_thaliana_Ch2_004014	0	-1
ATH02	1074117	1074515	Arabidopsis_thaliana_Ch2_000122	0	1
ATH02	1133514	1133702	Arabidopsis_thaliana_Ch2_003995	0	-1
ATH02	1135988	1136215	Arabidopsis_thaliana_Ch2_003994	0	-1


D

Chr05	167958	168626	Malus_domestica_Ch05_003014	0	-1
Chr05	1097801	1098475	Malus_domestica_Ch05_000011	0	1
Chr05	1415010	1415870	Malus_domestica_Ch05_000021	0	1
Chr05	1416840	1417406	Malus_domestica_Ch05_003000	0	-1
Chr05	1709448	1709762	Malus_domestica_Ch05_000029	0	1
Chr05	1715792	1716201	Malus_domestica_Ch05_000030	0	1
Chr05	1820067	1820882	Malus_domestica_Ch05_002992	0	-1
Chr05	1841647	1841895	Malus_domestica_Ch05_002990	0	-1
Chr05	1925227	1925682	Malus_domestica_Ch05_000033	0	1
Chr05	1929146	1930579	Malus_domestica_Ch05_000034	0	1

Figure 10 : Extraits des fichiers .bed des CDS ratés (A & B) par Helixer et rajoutés (C & D) / (A, C : Arabidopsis. T ; B, D : Malus.D).
Ce format de fichier est lisible par les Genome Browsers. Le fichier .bed est sous le format suivant : {Chromosome, Position de départ, Position de fin, Nom du feature, Score, Sens}. Le score a été initié à 0 car celui exigé dans le format .bed représente une variable quantitative par rapport au feature (poids, valeur de confiance, niveau de signal, score de similarité) compris entre 0 et 1000. Concernant les sens, -1 désigne le sens 3'5' et 1 désigne le sens 5'3'.

Grâce à la génération de ces fichiers, nous voyons que le génome d'Arabidopsis thaliana contient bel et bien des transcrits alternatifs qui ont été annotés : Nom_du_gène.X comme nom de feature suggère que celui-ci est un transcrit alternatif si $X > 1$.

Cependant, nous avons pu voir qu'aucun transcrit alternatif n'a été annoté par les experts pour Malus domestica puisqu'aucune nomination n'avait le format suggérant un transcrit alternatif. En voyant de près toutes les données pour tous les chromosomes dans les fichiers .bed, on s'est interrogé si Helixer pouvait faire défaut à un endroit spécifique du génome.






Figure 11A : Répartition des CDS rajoutés par Helixer en fonction des chromosomes. Le barplot bleu correspond au génome d'*Arabidopsis.t* et le barplot orange correspond à celui du *Malus.d*. Cette figure a été obtenue via les fichiers .bed des CDS ajoutés.





Figure 11B : Répartition des CDS manqués par Helixer en fonction des chromosomes. Le barplot rouge correspond au génome d'*Arabidopsis.t* et le barplot vert correspond à celui du *Malus.d*. Cette figure a été obtenue via les fichiers .bed des CDS ratés.

Les figures ci-contre montrent que les ajouts ou les manques d'annotations Helixer sont homogènes, bien que pour les chromosomes ATHoC et ATHoM, les distributions soient drastiquement différentes. En effet, la taille de ces chromosomes explique ces résultats, car ces chromosomes présentent moins de loci que les autres chromosomes, dû à leur taille. Le but étant ici de voir les différences dans les annotations structurales, nous avons ensuite obtenu des résultats concernant les annotations qui sont quasiment ou exactement identiques.

Nous nous sommes alors intéressés aux loci annotés des deux côtés. En effet, grâce à la méthode *compare_all_feats()*, nous avons obtenu tous les CDS ayant la même annotation structurale (pourcentage d'identité à 100% et type d'égalité « = ») et tous les CDS ayant presque la même annotation structurale (seuil du pourcentage d'identité à 85% minimum et type d'égalité « ~ »). A partir de ces CDS obtenus, la méthode *compare_every utr()* a été utilisée pour comparer tous les ARNm correspondant à ces CDS, et renvoyer un rapport mettant en évidence le type d'égalité de ces ARNm, le score d'identité et les différences dans les régions UTR. Bien que l'outil ait été utilisé sur l'ensemble des génomes de la base de données GBOT, nous nous intéressons ici aux rapports générés pour *Arabidopsis thaliana* et *Malus domestica*. Pour *Arabidopsis thaliana*, 44.22% des loci en commun sont annotés de manière identique et moins de 1% des loci sont quasiment annotés de la manière. Pour *Malus domestica*, 49.96% des loci en commun sont annotés de manière identique et 3.35% des loci sont quasiment annotés de la manière.

Chromosome	Gène	Isoformes	Référence	Helixer	Score	Identité	Type Egalité	5 UTR	3 UTR
ATH02	AT2G01070	['AT2G01070.2']	AT2G01070.1	Arabidopsis_thaliana_Chv2_000001	90.62	~	~	TCTTCTTATCGCTCGATCGACGATTACATTATTGATATTTTATTGGT	
ATH02	AT2G01080	[]	AT2G01080.1	Arabidopsis_thaliana_Chv2_000002	80.77	~	~	GGTGGTTAAATGTGAACATT/TACTACGCTGCAATCGCTTGGC	
ATH02	AT2G01090	['AT2G01090.2', 'AT2G01090.3', 'AT2G01090.4']	AT2G01090.1	Arabidopsis_thaliana_Chv2_000003	71.84	j	j	TGCCCATGAATCAAGAGAATATTACACGGGCTCCGCTGTGGG	
ATH02	AT2G01100	['AT2G01100.2', 'AT2G01100.3']	AT2G01100.1	Arabidopsis_thaliana_Chv2_000004	95.7	~	~	TACAAGTC	ATCAATCATCTTGGTTTTTATCT
ATH02	AT2G01110	[]	AT2G01110.1	Arabidopsis_thaliana_Chv2_004115	87.83	~	~	CGTAGTTAAGAGGAGTGTGTACGTTGCCACATTGATATTTTCCA	
ATH02	AT2G01120	['AT2G01120.2']	AT2G01120.1	Arabidopsis_thaliana_Chv2_000005	94.59	~	~	AACCAATCCTTTTTTTTCTCC	TCATGCTAACAGTTAAGACCCGC
ATH02	AT2G01140	[]	AT2G01140.1	Arabidopsis_thaliana_Chv2_004113	86.86	~	~	CTGAACCTGCAACTATGCCAATT	AGTAGCTGCTACTTTGGCATCAI
ATH02	AT2G01150	['AT2G01150.3', 'AT2G01150.1']	AT2G01150.2	Arabidopsis_thaliana_Chv2_000006	95.58	~	~	GGGGCGAAAGTATGAAGATGG	TTCTGGTTTCCACACTTTG
ATH02	AT2G01180	['AT2G01180.5', 'AT2G01180.6', 'AT2G01180.3', 'AT2G01180.2']	AT2G01180.1	Arabidopsis_thaliana_Chv2_004111	62.85	~	~	ACGAATTAAG	CCTGGCTCCTGCCACCAAAAAACA
ATH02	AT2G01190	[]	AT2G01190.1	Arabidopsis_thaliana_Chv2_000007	95.55	~	~	ATTTACATACAAGTCGTG	TATCTGTTTTTCAAGAGACTTTG
ATH02	AT2G01210	[]	AT2G01210.1	Arabidopsis_thaliana_Chv2_004110	97.72	~	~	AAATTAGCTCACTGTGGTCTAT	ACCAAGAAAGAGGTGAAAGTTG
ATH02	AT2G01220	['AT2G01220.1']	AT2G01220.2	Arabidopsis_thaliana_Chv2_000009	95.81	~	~	CTAAACCTAAACCCAGAGAGAG	C
ATH02	AT2G01250	['AT2G01250.2']	AT2G01250.1	Arabidopsis_thaliana_Chv2_004108	94.01	~	~	GGATTACTTAATCCAATGGGCCA	ATGCTTCTCAAATTAGGTTAACTA
ATH02	AT2G01260	['AT2G01260.2', 'AT2G01260.3']	AT2G01260.1	Arabidopsis_thaliana_Chv2_004107	97.55	~	~	CGAAAT	AGTAATTGGAGGGGAGAGACA
ATH02	AT2G01275	['AT2G01275.2', 'AT2G01275.4', 'AT2G01275.3', 'AT2G01275.1']	AT2G01275.1	Arabidopsis_thaliana_Chv2_004106	93.89	~	~	TTGTCTATCTATCTGCTGCTGAC	TTAACAAAGCTCTTCTTTCT/
ATH02	AT2G01290	[]	AT2G01290.1	Arabidopsis_thaliana_Chv2_004105	95.75	~	~	CTAACACGATTCATGTTTCGGCG	TGTTTT
ATH02	AT2G01300	[]	AT2G01300.1	Arabidopsis_thaliana_Chv2_004104	76.04	~	~	GTAAT	ATTTATAACATTGGATAATACTAT
ATH02	AT2G01320	['AT2G01320.3', 'AT2G01320.1', 'AT2G01320.4', 'AT2G01320.2']	AT2G01320.1	Arabidopsis_thaliana_Chv2_004103	96.63	~	~	GGTGTGATTTGACTTTTCCCAAC	

Figure 12 : Extrait d'un fichier .tsv généré pour le génome *Arabidopsis thaliana* pour la comparaison d'ARNm dont les loci sont identiques. D'autres fichiers .tsv ont été obtenus, avec les mêmes colonnes pour les cas ~ et = pour tous les génomes.

Bien que notre outil ait généré un rapport concerné les ARNm correspondant aux locis presque ou exactement identiques, la sortie pourrait être améliorée. En effet, pour les colonnes 5'UTR et 3'UTR, les positions de départ et de fin de la séquence insérée par rapport à l'autre annotation auraient pu la remplacer. Pour les fichiers obtenus pour *Arabidopsis thaliana* et *Malus domestica*, plus de 95% des ARNm sont quasiment similaires (« ~ »), mais aucune annotation d'ARNm n'a été repéré comme étant exactement identique à l'autre. En revanche, il est important de noter que même une différence d'une paire de base compte comme « ~ ». Les résultats ont alors été filtrés et nous avons prêté attention aux ARNm ayant plus de 95% de score d'identité.

ARNm	<i>Arabidopsis thaliana</i>	<i>Malus domestica</i>
Pour les locis annotés « ~ »	23.65%	20.345%
Pour les locis annotés « = »	38%	28.34%

Figure 12 : Proportion d'ARNm annotés à plus de 95% d'identité dont les locis étaient catégorisés « = » ou « ~ » pour *Arabidopsis T* et *Malus D*. Etant donné qu'aucune annotation d'ARNm n'est montrée comme « = » à celle de référence, nous considérons que les ARNm ayant plus de 95% d'identité sont identiques.

Les loci sont, dans leur majorité, annotés de manière similaire par Helixer comparé à l'annotation de référence. Cependant, les annotations des ARNm correspondants présentent des différences plus marquées, bien que leurs structures globales restent largement conservées. Ces variations se concentrent principalement au niveau des régions UTR, comme le révèle notre outil d'analyse. Cela pourrait expliquer pourquoi un tiers des ARNm présentent une similarité structurelle d'au moins 95 %. Il est à noter qu'aucun ARNm n'a été annoté de façon strictement identique à la référence par Helixer.

CONCLUSION & PERSPECTIVES

Ce stage a permis de développer un outil de comparaison structurale des annotations génomiques, facilitant l'analyse des différences entre une annotation de référence et celle prédite par Helixer. L'approche mise en place a révélé une forte similitude au niveau des loci annotés, malgré des divergences notables sur les structures des ARNm, notamment au sein des régions UTR. Ces résultats témoignent de la pertinence de l'annotation par Deep Learning, tout en soulignant les limites actuelles dans la reproduction exacte des structures d'ARNm complexes. L'outil conçu a permis non seulement de produire des

fichiers exploitables pour la visualisation (formats .bed et .tsv), mais aussi de fournir un cadre robuste pour l'étude comparative de génomes annotés. Il représente une étape importante vers l'intégration automatique de ces analyses dans la base GBOT, contribuant ainsi à améliorer l'interprétation et la qualité des annotations structurales disponibles.

Plusieurs pistes peuvent être envisagées pour optimiser les performances de l'outil. En effet, actuellement, l'analyse de cinq génomes (*Arabidopsis Thaliana*, *Brachypodium distachyon*, *Malus domestica*, *Rosa chinensis*, *Solanum lycopersicum*) prend environ 30 minutes. L'implémentation d'arbres d'intervalles permettrait d'optimiser la recherche de chevauchements entre features, réduisant significativement la complexité algorithmique. Bien que les fichiers .tsv générés soient fonctionnels, leur lisibilité pourrait être renforcée. Il serait pertinent soit de remplacer ce format par un type de fichier plus structuré (JSON...), soit d'ajuster certaines colonnes pour intégrer des informations plus précises (ex. : positions exactes des régions UTR différentielles au lieu de séquences complètes). De plus, une intégration graphique des résultats au site web GBOT (via des widgets interactifs ou une section "Comparaison Helixer/Expert") permettrait une visualisation dynamique et conviviale des différences d'annotation, directement accessible aux utilisateurs sans traitement manuel des fichiers.

Ces évolutions contribueraient à faire de l'outil un composant central de GBOT, renforçant l'accessibilité et l'analyse comparative dans le domaine de l'annotation génomique par intelligence artificielle.

REMERCIEMENTS

Je tiens à remercier chaleureusement Franck Samson et Véronique Brunaud, mes encadrants tout au long de ce stage, pour leur accompagnement, leur disponibilité et la qualité de leurs conseils. Je leur suis également reconnaissant de m'avoir offert l'opportunité de travailler sur le projet GBOT, au cœur d'une thématique aussi passionnante que formatrice. Merci également à toute l'équipe du LaMME pour son accueil chaleureux, les échanges enrichissants, ainsi que l'ambiance de travail dynamique et stimulante que j'ai pu découvrir au fil des semaines passées parmi eux.

RÉFÉRENCES

Holst, Felix, Anthony Bolger, Christopher Günther, Janina Maß, Sebastian Triesch, Felicitas Kindel, Niklas Kiel, et al. « Helixer—de novo Prediction of Primary Eukaryotic Gene Models Combining Deep Learning and a Hidden Markov Model ». *bioRxiv*, 1 janvier 2023, 2023.02.06.527280. <https://doi.org/10.1101/2023.02.06.527280>.

Samson, Franck, et Sébastien Aubourg. « GBOT One Flew over the Ortholog's Nest », 2024. <https://hal.inrae.fr/hal-04831777>.

Alexandre CORMIER. « AI to the rescue of structural annotation ? », 2024. <https://merit.cnrs.fr/wp-content/uploads/2024/11/2024-11-07-06-CORMIER.pdf>

Véronique Brunaud. « Arabidopsis structural annotation is not perfect ! », 2025. <https://pepi-ibis.inrae.fr/annotation-genomes>

Table of Contents

ABSTRACT	2
INTRODUCTION.....	2
MATERIALS & METHODS	3
1. <i>Materials</i>	3
2. <i>Methods</i>	6
2.1 <i>Detection of annotations not included by Helixer or by experts</i>	7
2.2 <i>Comparison of features common to Helixer and experts</i>	8
2.3 <i>Comparison of UTR regions of Helixer and Expert mRNAs</i>	11
2.4 <i>Exporting results</i>	11
RESULTS & DISCUSSION	12
CONCLUSION & OUTLOOK.....	17
ACKNOWLEDGEMENTS.....	18
REFERENCES	19

Comparison of structural gene annotation in the GBOT database (Genome Browser & Orthologs Tracker).

Akshay MOHAMMED KHOKAN¹, Franck SAMSON², Véronique BRUNAUD² ¹Double-Degree Bachelor's student: Biology and Computer Science

² INRAE Research Engineer: Tutor and Co-supervisor of the internship

ABSTRACT

This internship focused on developing a bioinformatics tool designed to compare two genomic annotations: a reference annotation and an annotation predicted by Helixer (*Felix Holst et al.*, February 2023), a deep learning-based tool. We developed a tool in Python to analyse and compare gene structures using the GBOT database. SQL queries were used to query the database, facilitating the extraction and analysis of relevant biological data. The tool generates detailed reports highlighting the differences between annotations and will be integrated into the GBOT web interface to enable interactive visualisation of the results. This work contributes to improving the quality of genomic annotations and provides a reusable solution for future comparisons. GBOT is accessible via the following URL:

<http://stat.genopole.cnrs.fr/server/GBOT/index.html>.

INTRODUCTION

Genomic annotation is a crucial step in biology, as it serves to identify important elements of a genome, such as genes, exons, introns and regulatory regions. Faced with species diversity and the increasing complexity of genomes, new approaches, particularly those based on artificial intelligence, have emerged to improve the accuracy of annotations. In this context, Helixer, a next-generation annotation tool using deep neural networks, offers a promising alternative to traditional methods. Indeed, structural annotations made by experts are based on RNA-Seq (unlike Helixer). However, it is essential to compare the annotations generated by Helixer with reference annotations to assess their reliability and detect structural discrepancies.

These structural annotations can be visualised on Genome Browsers, and this internship focuses on one of them: GBOT (Genome Browser & Orthologs Tracker). Although *Drosophila* species are present there, only the genomes of plant species (such as *Arabidopsis thaliana*, *Brachypodium distachyon*, *Malus domestica*, *Rosa chinensis*) have been annotated by Helixer. This internship is therefore part of this approach to comparing genomic annotations, with the aim of developing an automated Python tool to:

- Analysing the differences between two sets of annotations (reference vs Helixer),
- To efficiently query a relational database (GBOT) via SQL,
- And generate visual reports that can be integrated into the GBOT website to facilitate the interpretation of results.

This work enables the evaluation of the effectiveness of artificial intelligence in genomic annotation, although it is limited solely to plant genomes.

MATERIALS & METHODS

1. Materials

As this work focuses on GBOT, this tool was designed to explore homology relationships between genes and proteins. It offers a new visualisation platform that facilitates the study of homologous gene families and the prediction of orthologs. (*F. Samson & S. Aubourg, 09/2024*)




Figure 1: GBOT web interface. *Search pattern:* Allows you to search for a specific sequence in the genome. *Blast sequence:* Launches a BLAST search based on a given sequence. *PFAM motif:* Displays the protein domains detected in the genes. *mRNA:* Visualises the annotated mRNAs in the selected region. *Blast result:* Shows the aligned results of the BLAST search. *Feature menu:* Provides access to the various available annotations. *CDS:* Displays the coding sequences (translated exons) of the genes. *Select species:* Choose the species to display for comparison. *Sequence position:* Indicates the exact position of the genomic sequences. *Chromosome view:* Displays chromosome alignments between species. *BLAST result (comparative):* Shows BLAST alignments between homologous genes from different species.

It helps to better understand gene evolution across different species and to transfer functional knowledge between them, particularly in the context of genome annotation. It is therefore important to specify how it works, as illustrated in the following figure:




Figure 2: Functional diagram of GBOT. The web interface uses JavaScript exclusively for the presentation layer, connected to a PostgreSQL database that enables the storage and querying of genomic data. A layer coded in Python acts as an intermediary between the client's browser and the database server via an API. The web interface, which allows the visualisation of homology relationships within gene families across multiple species, is based on WASM and displays database queries via json outputs.

To study differences in genomic annotations, a bioinformatics comparison tool was coded in Python 3.12 for the logic, with calls to the PostgreSQL database to extract information directly coded in SQL. However, the work focused solely on plants, as the team concentrated on studying plants using IPS2 and therefore did not search for Helixer annotations on the Drosophila species contained in the database.

The genomic annotations in our datasets were obtained in a different way. Helixer is a de novo tool for predicting eukaryotic gene structures, combining deep learning and hidden Markov models (HMMs). The aim is to produce biologically coherent annotations directly from

raw DNA sequences, without the need for additional experimental data. Using trained neural networks, Helixer accurately identifies key elements such as start/stop codons, splicing sites and UTRs. These predictions are then refined by an HMM, which checks whether they comply with biological rules (coding frames, intron types, etc.). The final result is provided in .gff3 format, fully readable by Genome Browsers, allowing direct visualisation of annotated gene models. Expert annotation was obtained via RNA-Seq, unlike Helixer, which learns from RefSeq and Phytozome13 annotations (for plant genomes) and, once trained, no longer requires these or RNA-Seq to make its predictions. Indeed, expert gene annotation based on RNA-Seq data relies on the use of messenger RNA sequences that are extracted, sequenced, and then aligned to the genome to reconstruct the structure of expressed genes. This approach allows for the precise identification of exons, splicing sites, splicing variants (isoforms) and the exact start and end positions of transcription. The RNAs are then aligned, and gene models are established using these alignments. It is worth noting a major difference between the two annotations: Helixer considers only a single transcript, whereas RNAseq annotation takes into account all alternative transcripts.

Although GBOT offers the ability to visualise features such as ncRNAs, PFAMs and tRNAs, the comparison focused solely on coding sequences (CDSs) and mRNAs, as only these features were predicted by Helixer for the plant genomes in the database.

The annotation of CDSs in the GBOT database was carried out by the consortia responsible for annotating each plant species. For example, for *Arabidopsis thaliana*, the sequence data comes from the TAIR10 version, whilst the CDS and mRNA annotations were retrieved from Araport11, the latest version of the reference structural annotation. As for *Malus domestica*, the genome annotation used in GBOT is derived from the high-quality GDDH13 v1.1 assembly, developed by the Bucher Lab team (INRAE, Angers); however, unlike *Arabidopsis thaliana*, no alternative transcript annotations are provided.

2. Methods

The work of comparing genomic annotations was divided into several layers of analysis, as shown in the following flowchart:




Figure 3: Flowchart of the structural annotation comparison tool. The tool relies on the GBOT modules, hence their importation prior to creating the methods. The following sections detail each of these.

2.1 Detection of annotations not included by Helixer or by experts

This first layer identifies what Helixer predicted but which the experts did not annotate. It also detects features annotated by the experts that were not predicted by Helixer. This first layer was established using the *find_MissingAnnotationsV1()* method. Although this method allows work on all types of features annotated by Helixer and the experts, its use was limited to coding sequences. Indeed, in the GBOT database, all CDSs of a chromosomal sequence for a species can be retrieved via an SQL query. This query then retrieves all CDS annotated by experts (meaning alternative CDS are taken into account), and those annotated by Helixer. A method called *are_overlapping()* was thus created to determine whether two features overlap.

The figure opposite shows how overlapping CDSs were identified:




Figure 4A: Detection of overlaps between Helixer CDSs and Expert CDSs. There are several cases of overlap, and detection is based on the start and stop positions of the features. Indeed, if $\min(\text{stop1}, \text{stop2}) - \max(\text{start1}, \text{start2}) > 0$, then there is an overlap. If this condition is not met, Helixer has missed the expert annotation or vice versa. It is through this reasoning that we were able to identify additions and omissions in the Helixer annotation.




Figure 4B: Detection of CDSs added or missed by Helixer. (In red: Helixer, in blue: the expert annotation) Helixer CDSs do not overlap with a reference annotation in any way, and likewise, a reference annotation does not overlap with a Helixer CDS in any way. The CDS is therefore either missed or added by Helixer compared to the expert annotation.

2.2 Comparison of common Helixer and Expert features

Using the `are_overlapping()` method, we were able to focus on the Helixer and Expert features that overlap. However, an overlap does not mean that the two features are identical. This is how the second layer of work was established using the `compare_all_feats()` method. This method utilises the `get_score()`, `obtain_both_feats()`, and `compare_both_feats()` methods. Before reviewing the first method, it is important to explain the others.

The `obtain_both_feats()` method retrieves all features annotated simultaneously by Helixer and the experts (which overlap), and therefore relies on the `are_overlapping()` function. In order to compare the features together, an identity scoring system has been implemented. Indeed, the `get_score()` method calculates a score by taking into account a start position and an end position. The `compare_both_feats()` method, meanwhile, calculates the identity score between two features by comparing them exon by exon, then takes into account the arrangement of the introns to determine the type of match between the two features.




Figure 5: Different types of feature equivalence (established by the E2annot project). "=": Not all exons are the same, but the intron sequences are; "c": Helixer introns are contained within the reference annotation; "k": Helixer introns contain the reference annotation, "m": All reference introns are covered/matched, "j": At least one match between exons, "n": Not all reference introns are matched.

There are indeed several types of feature overlaps, and we drew on the work carried out by the *e2annot* project (*Extend Eukaryote Annotation with transcriptome data*) to ensure the tool returns the type of equality for our features.

However, the "=" type was not considered as such when designing the comparison tool. In fact, we created a new type, "j", to classify features that

enables exonic and intronic comparison of features, in order to ensure that features fall. To calculate the identity score between two features, we overlap the one (or ones) in the other annotation. Once the calculated score constitutes the identity score. For each exon that is not matched, the score is set to 0. This system then takes into account the different




Figure 6: Different cases of annotated CDS types (Helixer annotation: red / Expert annotation: blue)

5A: Helixer CDS and Expert CDS with one or more introns. **5B:** Helixer CDS and Expert CDS with a single exon. **5C:** Helixer CDS with one or more introns versus Expert CDS with only one exon (the reverse is possible). Identical CDSs are shown in 4A and 4B; they may differ even though the structural type is the same.

The `compare_all_feats()` method then takes into account a threshold identity score as a parameter and the type of feature equality one wishes to see. It thus applies `compare_both_feats()` to each overlap found via `obtain_both_feats()`. A report is therefore generated with the score and the type of overlap equality for an entire genome. However, the `compare_all_feats()` method also allows us to identify all alternative transcripts and selects the one most similar to the Helixer annotation (the isoform with the highest identity score). The generated report still displays a list of alternative transcripts (if any) for the transcript identified by `compare_all_feats()`.




Figure 7: Helixer vs. Isoforms (Helixer annotation: red / Expert annotation: blue)

Although there are two isoforms, `compare_all_feats()` would return isoform 1 (score of 100%) here, and the equality type would be '='.

Isoform 2 would have a score < 100 and an equality type of 'm', but would be placed in the list of alternative transcripts.

2.3 Comparison of the UTR regions of the Helixer and Expert mRNAs

Using the methods described in the sections above, we were able to study the UTR regions of Helixer and Expert mRNAs. Indeed, although the CDS annotations are almost or exactly the same, the mRNAs themselves may have differences in annotations within the UTR regions.



Figure 8: Differences in mRNA annotations in the UTR regions (Helixer CDS: red, Helixer mRNA: orange / Expert CDS: dark blue, Expert mRNA: light blue)

Although the CDSs here are identical, this is not the case for the mRNAs, which are almost similar. Helixer exhibits an extension in the 3'UTR compared to the reference, and a deletion in the 5'UTR compared to the reference.

Two methods have therefore been created to enable comparison of the UTR regions of the two annotations: *comparing_UTR()* and *compare_every_UTR()*.

The first method compares two features by focusing on the 5'UTR and 3'UTR regions. It identifies and returns only the sequence present in one annotation but absent in the other, corresponding to an insertion. In order to analyse only the UTR regions, we obtained the mRNA and CDS sequences via SQL queries. We know that UTR regions correspond to the non-coding parts of the mRNA, i.e. the mRNA excluding the CDS. The UTR regions were therefore obtained by excluding the CDS sequences from the mRNAs. Furthermore, this method also analyses the two mRNA annotations via *'compare_both_feats()'*. It then returns a report in the following format: {Reference chromosome, Reference gene, Reference feature, Helixer feature, List of isoforms, Identity score, Equality type, Difference in 5'UTR, Difference in 3'UTR}.

The second method thus allows the first to be applied to the entire list of features obtained via *compare_all_feats()*.

2.4 Exporting results

A final method has been created to analyse all the plant genomes in the database: *exporting_results()*. This method allows all the generated reports to be saved in file formats such as .bed and .tsv, for each genome.

RESULTS & DISCUSSION

Using the `exporting_results()` method, we obtained results for all plant genomes in the database, with the exception of *Zea Mays*. Before examining the .tsv and .bed files created using this method, here are some figures summarising all the results obtained.




Figure 9: Histogram obtained following the use of `findMissingAnnotations()` on all genomes. Helixer covers all the CDSs annotated by the experts. The annotations missed or added by Helixer are minimal, except for *Rosa chinensis*, for which Helixer annotated more CDSs compared to the other genomes. For the *Zea mays* genome, no annotations could be made by Helixer because the chromosomes were too large, leading to memory issues.

Species	Helixer	Expert
<u>Arabidopsis thaliana</u>	27035	48266
<u>Brachypodium distachyon</u>	30904	56835
<u>Malus domestica</u>	43640	45115
<u>Rosa chinensis</u>	43623	39668
<u>Solanum lycopersicum</u>	34074	29773

Figure 10: Summary table of CDSs annotated by Helixer and CDSs annotated by the Experts for each genome. The number of Expert CDSs also includes alternative CDSs, hence a higher number than Helixer for most genomes.

Although Helixer annotated fewer CDSs than the experts for most genomes, we observed that the majority of reference loci were covered by the Helixer annotation. This is because a CDS annotated by the deep learning-based tool may overlap with several alternative transcripts. However, for *Rosa chinensis*, Helixer annotated more CDS than the expert annotation, with an additional 12,196 CDS not included in the latter. The *Solanum lycopersicum* genome also presents a case where Helixer's CDS outnumber those annotated by experts, with 7,677 missed by the tool. The Helixer annotations for the other genomes, however, appear reliable, as the additions and missing CDSs are few in number compared to the CDSs that both annotations were able to identify. This means that the Helixer CDSs cover the majority of alternative transcripts, although fewer in number than the CDSs annotated by the experts.

Nevertheless, the annotation of the *Malus domestica* genome must be questioned, as the experts did not annotate any alternative transcripts at all. Indeed, the number of annotated CDSs is roughly equal (43,640 Helixer vs 45,115 Expert), but only 38,005 CDSs were predicted by both annotations (with 7,110 missed and 5,910 CDSs added by Helixer).

.bed files were generated: one to identify the CDSs added by Helixer and another for the CDSs missed by Helixer. The files were generated for all genomes, but those of *Arabidopsis thaliana* and *Malus domestica* were examined in greater detail.

A						B					
ATH02	1025	2111	AT2G01008.1	0	1	Chr05	87650	91257	MD05G1000300	0	-1
ATH02	6571	6672	AT2G01021.1	0	1	Chr05	177915	178151	MD05G1000600	0	-1
ATH02	9648	9767	AT2G01023.1	0	-1	Chr05	1091054	1091527	MD05G1003000	0	-1
ATH02	50345	51487	AT2G01035.1	0	-1	Chr05	1234489	1235314	MD05G1003600	0	-1
ATH02	53326	54468	AT2G01045.1	0	-1	Chr05	1386427	1386689	MD05G1005200	0	-1
ATH02	68337	69884	AT2G01050.1	0	-1	Chr05	1464306	1464497	MD05G1005700	0	1
ATH02	73456	74556	AT2G01060.2	0	-1	Chr05	1486551	1487268	MD05G1006000	0	-1
ATH02	73456	74902	AT2G01060.1	0	-1	Chr05	1523353	1523695	MD05G1006200	0	-1
ATH02	152481	152642	AT2G01310.1	0	-1	Chr05	1624434	1625120	MD05G1006500	0	-1
ATH02	171098	171343	AT2G01379.1	0	1	Chr05	1634613	1634910	MD05G1006600	0	1
ATH02	249687	250181	AT2G01554.1	0	1	Chr05	1636289	1636896	MD05G1006700	0	-1
ATH02	332249	332770	AT2G01755.1	0	-1	Chr05	1694371	1695440	MD05G1007100	0	-1
ATH02	332249	332788	AT2G01755.2	0	-1	Chr05	1769931	1772953	MD05G1007400	0	1

C


ATH02	598112	599525	Arabidopsis_thaliana_Ch2_004052	0	-1
ATH02	613163	614739	Arabidopsis_thaliana_Ch2_004048	0	-1
ATH02	636287	636607	Arabidopsis_thaliana_Ch2_004043	0	-1
ATH02	792503	793028	Arabidopsis_thaliana_Ch2_004032	0	-1
ATH02	850349	850676	Arabidopsis_thaliana_Ch2_000090	0	1
ATH02	936085	936543	Arabidopsis_thaliana_Ch2_000099	0	1
ATH02	982173	982474	Arabidopsis_thaliana_Ch2_004014	0	-1
ATH02	1074117	1074515	Arabidopsis_thaliana_Ch2_000122	0	1
ATH02	1133514	1133702	Arabidopsis_thaliana_Ch2_003995	0	-1
ATH02	1135988	1136215	Arabidopsis_thaliana_Ch2_003994	0	-1

D

Chr05	167958	168626	Malus_domestica_Ch05_003014	0	-1
Chr05	1097801	1098475	Malus_domestica_Ch05_000011	0	1
Chr05	1415010	1415870	Malus_domestica_Ch05_000021	0	1
Chr05	1416840	1417406	Malus_domestica_Ch05_003000	0	-1
Chr05	1709448	1709762	Malus_domestica_Ch05_000029	0	1
Chr05	1715792	1716201	Malus_domestica_Ch05_000030	0	1
Chr05	1820067	1820882	Malus_domestica_Ch05_002992	0	-1
Chr05	1841647	1841895	Malus_domestica_Ch05_002990	0	-1
Chr05	1925227	1925682	Malus_domestica_Ch05_000033	0	1
Chr05	1929146	1930579	Malus_domestica_Ch05_000034	0	1

Figure 10: Extracts from the .bed files of CDSs missed (A & B) by Helixer and added (C & D) / (A, C: Arabidopsis.T; B, D: Malus.D). This file format is readable by Genome Browsers. The .bed file is in the following format: {Chromosome, Start position, End position, Feature name, Score, Direction}. The score was initialised to 0 because the score required in the .bed format represents a quantitative variable relative to the feature (weight, confidence value, signal level, similarity score) ranging from 0 to 1000. Regarding orientation, -1 denotes the 3'5' orientation and 1 denotes the 5'3' orientation.

Thanks to the generation of these files, we can see that the Arabidopsis thaliana genome does indeed contain alternative transcripts that have been annotated: the feature name Gene_Name.X suggests that this is an alternative transcript if $X > 1$. However, we observed that no alternative transcripts had been annotated by experts for Malus domestica, as no entry had the format suggesting an alternative transcript. Upon closer examination of all the data for all chromosomes in the .bed files, we wondered whether Helixer might be failing at a specific location in the genome.






Figure 11A: Distribution of CDS added by Helixer by chromosome. The blue bar chart corresponds to the *Arabidopsis.t* genome and the orange bar chart corresponds to that of *Malus.d*. This figure was obtained from the .bed files of the added CDSs.





Figure 11B: Distribution of CDSs missed by Helixer by chromosome. The red bar chart corresponds to the Arabidopsis genome and the green bar chart to that of Malus. This figure was obtained from the .bed files of the missed CDSs.

The figures opposite show that the additions or omissions in Helixer annotations are consistent, although for the ATH0C and ATH0M chromosomes, the distributions are drastically different. Indeed, the size of these chromosomes explains these results, as these chromosomes have fewer loci than the other chromosomes, due to their size.

As the aim here was to examine differences in structural annotations, we subsequently obtained results concerning annotations that are almost or exactly identical.

We then focused on the loci annotated on both sides. Indeed, using the *compare_all_feats()* method, we obtained all CDSs with the same structural annotation (100% identity percentage and '=' equality type) and all CDSs with almost the same structural annotation (minimum identity percentage threshold of 85% and '~' equality type). Using these CDS, the *compare_every utr()* method was employed to compare all mRNAs corresponding to these CDS, and to generate a report highlighting the equality type of these mRNAs, the identity score, and the differences in the UTR regions. Although the tool was applied to all genomes in the GBOT database, we are focusing here on the reports generated for Arabidopsis thaliana and Malus domestica. For Arabidopsis thaliana, 44.22% of shared loci are annotated identically and less than 1% of loci are annotated almost identically. For Malus domestica, 49.96% of shared loci are annotated identically and 3.35% of loci are annotated almost identically.

Figure 12: Extract from a .tsv file generated for the Arabidopsis thaliana genome for the comparison of mRNAs with identical loci. Other .tsv files were obtained, with the same columns for the ~ and = cases for all genomes.

Chromosome	Gène	Isoformes	Référence	Helixer	Score	Identité	Type	Egalité	5 UTR	3 UTR
ATH02	AT2G01070	['AT2G01070.2']	AT2G01070.1	Arabidopsis_thaliana_Ch2_000001	90.62	~			TCTTCTTATCGCTCGATCGACGA	TTACATTATTGATATTTTATTGGTC
ATH02	AT2G01080	[]	AT2G01080.1	Arabidopsis_thaliana_Ch2_000002	80.77	~			GGTGGTTAAAATTGTGAAACATT	TACTCACGCTGCAATCGCTTGGC
ATH02	AT2G01090	['AT2G01090.2', 'AT2G01090.3', 'AT2G01090.4']	AT2G01090.1	Arabidopsis_thaliana_Ch2_000003	71.84	j			TGCCCATGAATCAAGAGAATATT	ACACGGGCTCCGTCCGTGTGGG
ATH02	AT2G01100	['AT2G01100.2', 'AT2G01100.3']	AT2G01100.1	Arabidopsis_thaliana_Ch2_000004	95.7	~			TACAAGTC	ATCAATCATCTTGGTTTTTATAC
ATH02	AT2G01110	[]	AT2G01110.1	Arabidopsis_thaliana_Ch2_004115	87.83	~			CGTAGTTAAGAGGAGTGTGTAC	GTGCCCACATTGATATTTTCCA
ATH02	AT2G01120	['AT2G01120.2']	AT2G01120.1	Arabidopsis_thaliana_Ch2_000005	94.59	~			AACCCAATCCITTTTTTTTCTCC	TCATGCTAACAGTTAAGACCCGC
ATH02	AT2G01140	[]	AT2G01140.1	Arabidopsis_thaliana_Ch2_004113	86.86	~			CTGAACCTGCAACTATGCCAATT	AGTAGTCGTCTACTTTGGCATCA
ATH02	AT2G01150	['AT2G01150.3', 'AT2G01150.1']	AT2G01150.2	Arabidopsis_thaliana_Ch2_000006	95.58	~			GGGGCGAAAAGTATGAAGATGG	TTCTGGTTTCCACACTTTG
ATH02	AT2G01180	['AT2G01180.5', 'AT2G01180.6', 'AT2G01180.3', 'AT2G01180.2']	AT2G01180.1	Arabidopsis_thaliana_Ch2_004111	62.85	~			ACGAATTAAG	CCTGGTCCTGCCACCAAAACA
ATH02	AT2G01190	[]	AT2G01190.1	Arabidopsis_thaliana_Ch2_000007	95.55	~			ATTACATACAAGTCGTG	TATCTGTTTTTTCAAGAGACTTTG
ATH02	AT2G01210	[]	AT2G01210.1	Arabidopsis_thaliana_Ch2_004110	97.72	~			AAATTAGCTCACTGTGGTTCTAT	ACCAAAGAAAGAGGTGAAGTTG
ATH02	AT2G01220	['AT2G01220.1']	AT2G01220.2	Arabidopsis_thaliana_Ch2_000009	95.81	~			CTAAACCTAAACCCAGAGAGAG	C
ATH02	AT2G01250	['AT2G01250.2']	AT2G01250.1	Arabidopsis_thaliana_Ch2_004108	94.01	~			GGATTACTTAATCCAATGGGCCA	ATGCTTCTCAAATAGGTTAACTA
ATH02	AT2G01260	['AT2G01260.2', 'AT2G01260.3']	AT2G01260.1	Arabidopsis_thaliana_Ch2_004107	97.55	~			CGAAAT	AGTAATTGGAGGGGAGAGACA
ATH02	AT2G01275	['AT2G01275.2', 'AT2G01275.4', 'AT2G01275.3', 'AT2G01275.1']	AT2G01275.1	Arabidopsis_thaliana_Ch2_004106	93.89	~			TTTGCTATCTATCTGCATTGCAC	TTAACAAAAGCTTCCTTTCTTCT
ATH02	AT2G01290	[]	AT2G01290.1	Arabidopsis_thaliana_Ch2_004105	95.75	~			CTAACACGATTCATGTTTCGGCG	TGTTTT
ATH02	AT2G01300	[]	AT2G01300.1	Arabidopsis_thaliana_Ch2_004104	76.04	~			GTAAT	ATTTATAACATTTGGATAATACTAT
ATH02	AT2G01320	['AT2G01320.3', 'AT2G01320.1', 'AT2G01320.4', 'AT2G01320.2']	AT2G01320.1	Arabidopsis_thaliana_Ch2_004103	96.63	~			GGTGTGTATTGACTTTTTCCCA	AC

Although our tool generated a report concerning mRNAs corresponding to almost or exactly identical loci, the output could be improved. Indeed, for the 5'UTR and 3'UTR columns, the start and end positions of the inserted sequence relative to the other annotation could have been included instead. For the files obtained for *Arabidopsis thaliana* and *Malus domestica*, over 95% of the mRNAs are nearly identical ('~'), but no mRNA annotation was identified as being exactly identical to the other. However, it is important to note that even a difference of a single base pair counts as '~'. The results were then filtered, and we focused on mRNAs with an identity score of over 95%.

mRNA	<i>Arabidopsis thaliana</i>	<i>Malus domestica</i>
For loci annotated as '~'	23.65%	20.345%
For loci annotated with '='	38%	28.34%

Figure 12: Proportion of mRNAs annotated with more than 95% identity whose loci were categorised as '=' or '~' for *Arabidopsis T* and *Malus D*. Given that no mRNA annotation is shown as '=' to the reference, we consider mRNAs with more than 95% identity to be identical.

The majority of loci are annotated similarly by Helixer compared to the reference annotation. However, the annotations of the corresponding mRNAs show more marked differences, although their overall structures remain largely conserved. These variations are mainly concentrated in the UTR regions, as revealed by our analysis tool. This could explain why one-third of mRNAs exhibit at least 95% structural similarity. It should be noted that no mRNA was annotated by Helixer in a manner strictly identical to the reference.

CONCLUSION & OUTLOOK

This internship enabled the development of a tool for the structural comparison of genomic annotations, facilitating the analysis of differences between a reference annotation and that predicted by Helixer. The approach implemented revealed a high degree of similarity in the annotated loci, despite notable divergences in mRNA structures, particularly within the UTR regions. These results demonstrate the relevance of Deep Learning-based annotation, whilst highlighting current limitations in the exact reproduction of complex mRNA structures. The tool designed not only enabled the production of

files suitable for visualisation (.bed and .tsv formats), but also to provide a robust framework for the comparative study of annotated genomes. It represents an important step towards the automatic integration of these analyses into the GBOT database, thereby helping to improve the interpretation and quality of the available structural annotations.

Several avenues can be explored to optimise the tool's performance.

Currently, the analysis of five genomes (*Arabidopsis thaliana*, *Brachypodium distachyon*, *Malus domestica*, *Rosa chinensis*, *Solanum lycopersicum*) takes approximately 30 minutes. The implementation of interval trees would optimise the search for overlaps between features, significantly reducing algorithmic complexity. Although the generated .tsv files are functional, their readability could be improved. It would be appropriate either to replace this format with a more structured file type (JSON, etc.) or to adjust certain columns to include more precise information (e.g. exact positions of differential UTR regions instead of complete sequences).

Furthermore, integrating the results graphically into the GBOT website (via interactive widgets or a 'Helixer/Expert Comparison' section) would enable dynamic and user-friendly visualisation of annotation differences, directly accessible to users without the need for manual file processing.

These developments would help make the tool a central component of GBOT, enhancing accessibility and comparative analysis in the field of AI-driven genomic annotation.

ACKNOWLEDGEMENTS

I would like to extend my warmest thanks to Franck Samson and Véronique Brunaud, my supervisors throughout this internship, for their support, their availability and the quality of their advice. I am also grateful to them for giving me the opportunity to work on the GBOT project, at the heart of a subject that is as fascinating as it is educational. Thank you also to the entire LaMME team for their warm welcome, the enriching discussions, and the dynamic and stimulating working atmosphere I experienced during the weeks I spent with them.

REFERENCES

Holst, Felix, Anthony Bolger, Christopher Günther, Janina Maß, Sebastian Triesch, Felicitas Kindel, Niklas Kiel, et al. 'Helixer–de novo Prediction of Primary Eukaryotic Gene Models Combining Deep Learning and a Hidden Markov Model'. *bioRxiv*, 1 January 2023, 2023.02.06.527280. <https://doi.org/10.1101/2023.02.06.527280>.

Samson, Franck, and Sébastien Aubourg. "GBOT One Flew over the Ortholog's Nest", 2024. <https://hal.inrae.fr/hal-04831777>.

Alexandre CORMIER. "AI to the rescue of structural annotation?", 2024. <https://merit.cnrs.fr/wp-content/uploads/2024/11/2024-11-07-06-CORMIER.pdf>

Véronique Brunaud. "Arabidopsis structural annotation is not perfect!", 2025. <https://pepi-ibis.inrae.fr/annotation-genomes>